

Travail à présenter le 26/09/2025 à 18h00.

Groupe de deux(2) personnes.

Exercice : ACP d'indicateurs d'audit de serveurs

Le fichier serveurs_audit_acp_m2.csv contient 160 serveurs, onze indicateurs quantitatifs, un identifiant et un segment synthétique. Les données sont générées artificiellement pour cet exercice : aucune mesure opérationnelle réelle ni diagnostic de sécurité ne peut être déduit des résultats.

Questions

1. Importer le fichier, inspecter sa forme, les types, doublons, valeurs manquantes et dispersion. Séparer variables actives, identifiant et segment externe. Pourquoi exclure les deux dernières colonnes ?
2. Proposer une ACP sur covariance ou sur corrélation en justifiant le choix par les unités. Calculer la matrice de corrélation ; identifier au moins deux couples de variables fortement corrélées.
3. Effectuer l'ACP. Produire éboulis, variance cumulée et valeurs propres de la matrice de corrélation. Comparer critères de Kaiser (>1), seuil de 80 % et lecture du coude. Choisir le nombre d'axes *en fonction de l'objectif*.
4. Déterminer les corrélations variables–axes et les contributions aux trois premiers axes. Interpréter CP1, CP2 et CP3 sans oublier que le signe des composantes est arbitraire.
5. Construire le cercle des corrélations CP1–CP2 et une carte thermique CP1–CP3. Comparer contribution d'une variable à un axe et $\cos^2$ de représentation dans un plan.
6. Projeter les serveurs sur CP1–CP2, colorés par le segment externe. Calculer les $\cos^2$ des individus dans ce plan. Quels serveurs ne doivent pas être interprétés avec confiance à partir de ces deux axes ?
7. Repérer les cinq individus les plus éloignés de l'origine dans l'espace standardisé complet. Comparer à une recherche fondée seulement sur CP1–CP2. Pourquoi distance élevée ne signifie-t-elle pas nécessairement incident de sécurité ?

8. Reconstruire les données standardisées avec 2, 3 et 4 axes et calculer l'erreur quadratique moyenne. Vérifier que cette erreur égale $1 - \text{variance_expliquee_cumulee}$ avec la convention de standardisation utilisée.
9. Comparer les plans CP1–CP2 et CP1–CP3. Quel rôle les variables liées à la résilience et aux sauvegardes jouent-elles ? Donner une conclusion prudente sur l'usage de l'ACP en audit informatique.

Livrables

Fichier Python commenté, graphiques légendés et une interprétation de 15 à 20 lignes distinguant structure des données, exploration visuelle et portée opérationnelle. Le corrigé `corrige_serveurs_acp_m2.py` produit six graphiques et les tableaux numériques nécessaires.

Questions complémentaires d'approfondissement

10. Calculer les contributions de chaque serveur aux axes CP1 et CP3. Quelle est la contribution moyenne attendue ? Comparer cette notion au $\cos^2$ individuel : un serveur très contributif est-il toujours bien représenté dans CP1–CP2 ?
11. Pour chaque serveur, reconstruire ses onze variables standardisées avec deux axes puis calculer son erreur individuelle. Représenter erreur et distance totale à l'origine. Expliquer pourquoi un serveur éloigné de l'origine peut être mal reconstruit dans le premier plan.
12. Retirer temporairement le serveur le plus éloigné, réestimer la standardisation et l'ACP, puis comparer taux d'inertie et sous-espace CP1–CP3 par une distance entre projecteurs. Les signes des axes doivent-ils entrer dans cette mesure ? Ne jamais modifier le CSV original.
13. Par 150 rééchantillonnages bootstrap, étudier la stabilité du sous-espace CP1–CP3 ; expliquer pourquoi ce contrôle interne n'est pas une validation sur une nouvelle population.
14. Effectuer une analyse parallèle avec 150 permutations indépendantes des onze colonnes. Comparer valeurs propres observées au 95e percentile nul de même rang ; discuter l'accord ou non avec Kaiser.
15. Ajouter un nouveau profil fictif avec des indicateurs élevés de charge et d'exposition. Le projeter à l'aide du StandardScaler et du modèle ACP ajustés uniquement sur les 160 serveurs initiaux. Calculer son erreur de reconstruction avec trois axes. Pourquoi refitter l'ACP avec ce nouveau profil ferait-il perdre la comparabilité des coordonnées ?

16. Construire un tableau de bord récapitulatif des contributions, erreurs et $\cos^2$. Formuler une conclusion scientifiquement prudente : quels résultats sont descriptifs, lesquels suggèrent des vérifications opérationnelles, et qu'est-ce qui reste non démontré ?